

Relatório Projeto Parte 2

COE241 - Estatística e Modelos Probabilísticos

Projeto do Curso - Parte 2

IGOR VALAMIEL PEIXOTO NUNES - 124013709
igor.valamiel.20241@poli.ufrj.br

December 2025

Introdução

A segunda parte do trabalho consiste na utilização dos modelos paramétricos da primeira etapa para realizarmos testes de hipótese, comparando, nesse caso, o cliente 11 e o servidor 07.

O cliente 11 e o servidor 07 foram escolhidos pois se comportam de maneira diferente em variáveis distintas. Pode-se observar que:

- A variância de *Download Throughput* do cliente 11 é bem menor que a do servidor 07, ainda que a mediana de ambos seja próxima;
- A mediana de *Upload Throughput* do cliente 11 é menor que a do servidor 07, assim como sua variância, que é quase a metade da mesma do servidor;
- A mediana observada para o *RTT Download* do cliente 11 é maior que a do servidor 07;
- A mediana observada para o *RTT Upload* do cliente 11 é levemente maior que a do servidor 07, mas o servidor possui uma quantidade muito maior de valores atípicos (*outliers*);
- A variância do *packet loss* do cliente é menor que a do servidor, ainda que este possua mediana muito menor.

Observou-se também que, para o cliente 11, os maiores valores de *Upload Throughput* ocorrem com menores valores de *Packet Loss*, mas com variação considerável. Além disso, para o servidor 07 nota-se o mesmo comportamento, com a diferença que a variação dos valores é muito maior.

Para essa parte do trabalho, foram escolhidas as variáveis *Upload Throughput* e *RTT Upload*, pois ambas apresentaram excelentes coeficientes de determinação ($R^2 \geq 0.90$) para os modelos testados na parte 1.

Testes de Hipótese

Teste de Razão de Verossimilhança (LRT) Modelo Gama Gama para Upload Throughput

Considere Y_{Ci} e Y_{Si} o *Upload Throughput* do Cliente 11 e do Servidor 07, respectivamente, com $i \in [1, n]$, sendo n o número de eventos de cada um deles. Usando o modelo:

$$Y_{Di} | \beta_D \sim \text{Gamma}(k, \beta_D), \text{ com } k > 0 \text{ conhecido e } \beta_D > 0 (\text{rate}) \text{ e PDF: } f(y | \beta_D) = \frac{\beta_D^k}{\Gamma(k)} y^{k-1} e^{-\beta_D y}, \quad y > 0.$$

Será feito um teste de razão de verossimilhança (LRT) para testar se ambos servidor e cliente possuem a mesma taxa:

- $H_0 : \beta_{Ci} = \beta_{Si} = \beta$
- $H_1 : \beta_{Ci} \neq \beta_{Si}$

Com a fórmula: $\Lambda = \frac{L_0(\hat{\beta})}{L_1(\hat{\beta}_{Ci}, \hat{\beta}_{Si})}$, $-2 \log \Lambda \approx \chi_1^2$ sob H_0 .

1) Verossimilhança sobre H_0 :

Para $\beta_{Ci} = \beta_{Si} = \beta$, temos que a verossimilhança é: $L_0(\beta) = \prod_{i=1}^{n_C} f(Y_{Ci}|\beta) \cdot \prod_{i=1}^{n_S} f(Y_{Si}|\beta)$

Substituindo a fórmula da PDF Gamma, temos que:

- $L_0(\beta) = \left(\frac{\beta^k}{\Gamma(k)}\right)^{n_C+n_S} \cdot \prod Y^{k-1} e^{-\beta \sum Y}$
- $\ell_0(\beta) = (n_C + n_S)k \log \beta - (n_C + n_S) \log \Gamma(k) + (k-1) \sum \log Y - \beta \sum Y$

Derivando e igualando a zero, encontramos a MLE: $\hat{\beta} = \frac{k(n_C+n_S)}{\sum Y}$

Logo, $\hat{\beta} = 3,12514634776473 \cdot 10^{-9}$ e $\ell_0 = -88303.68566293869 \rightarrow L_0 \approx 0.0$

2) Verossimilhança sobre H_1 :

Para $\beta_{Ci} \neq \beta_{Si}$, temos que a verossimilhança é: $L_1(\beta_C, \beta_S) = \prod_{i=1}^{n_C} f(Y_{Ci}|\beta_C) \cdot \prod_{i=1}^{n_S} f(Y_{Si}|\beta_S)$

Substituindo a fórmula da PDF Gamma, temos que:

- $L_1(\beta) = \left(\frac{\beta_C^k}{\Gamma(k)}\right)^{n_C} \left(\frac{\beta_S^k}{\Gamma(k)}\right)^{n_S} \cdot \prod Y^{k-1} \cdot e^{-\beta_C \sum Y_C - \beta_S \sum Y_S}$
- $\ell_1 = n_C k \log \beta_C + n_S k \log \beta_S - (n_C + n_S) \log \Gamma(k) + (k-1) \sum \log Y - \beta_C \sum Y_C - \beta_S \sum Y_S$

Derivando e igualando a zero, encontramos as MLEs: $\hat{\beta}_C = \frac{n_C k}{\sum Y_C}$ e $\hat{\beta}_S = \frac{n_S k}{\sum Y_S}$

Logo, $\hat{\beta}_C = 5.004069563682771 \cdot 10^{-9}$, $\hat{\beta}_S = 2.979125271263372 \cdot 10^{-9}$ e $\ell_1 = -88235.50432927081 \rightarrow L_1 \approx 0.0$

3) Montrando aproximação da LRT:

Usando o teste da razão de verossimilhança (LRT): $\Lambda = \frac{L_0(\hat{\beta})}{L_1(\hat{\beta}_C, \hat{\beta}_S)}$, $-2 \log \Lambda \approx \chi_1^2$ sob H_0 .

Para facilitar as contas, os cálculos foram feitos diretamente na forma logarítmica, logo o LRT foi transformado:

$$\Lambda = \frac{L_0(\hat{\beta})}{L_1(\hat{\beta}_C, \hat{\beta}_S)} \rightarrow \log \Lambda = \log\left(\frac{L_0(\hat{\beta})}{L_1(\hat{\beta}_C, \hat{\beta}_S)}\right) = \log(L_0(\hat{\beta})) - \log(L_1(\hat{\beta}_C, \hat{\beta}_S)) = \ell_0(\hat{\beta}) - \ell_1(\hat{\beta}_C, \hat{\beta}_S)$$

Considerando $\bar{Y}$ a média conjunta do Throughput, $\bar{Y}_C$ e $\bar{Y}_S$ as médias amostrais e n_C e n_S os tamanhos das amostras do cliente 11 e do servidor 07, respectivamente, temos que:

- $\ell_0(\hat{\beta}) = nk \log\left(\frac{k}{\bar{Y}}\right) - n \log \Gamma(k) + (k-1) \sum \log Y - nk$
- $\ell_1(\hat{\beta}_C, \hat{\beta}_S) = n_C k \log\left(\frac{k}{\bar{Y}_C}\right) + n_S k \log\left(\frac{k}{\bar{Y}_S}\right) - n \log \Gamma(k) + (k-1) \sum \log Y - nk$

Então:

$$\begin{aligned} -2 \log \Lambda &= 2 \cdot (\ell_1(\hat{\beta}_C, \hat{\beta}_S) - \ell_0(\hat{\beta})) = \\ &= 2[nk \log\left(\frac{k}{\bar{Y}}\right) - n_C k \log\left(\frac{k}{\bar{Y}_C}\right) - n_S k \log\left(\frac{k}{\bar{Y}_S}\right)] = \\ &= 2k \left[n_C \log\left(\frac{\bar{Y}}{\bar{Y}_C}\right) + n_S \log\left(\frac{\bar{Y}}{\bar{Y}_S}\right) \right] \end{aligned}$$

4) Conclusão de hipótese para $\alpha = 0.05$:

Escolhendo um *type 1 error* $\alpha = 0.05$:

$$W_{\text{obs}} = 2k \left[n_C \log\left(\frac{\bar{Y}}{\bar{Y}_C}\right) + n_S \log\left(\frac{\bar{Y}}{\bar{Y}_S}\right) \right] = 136.36266733573592$$

$$\chi_{1,1-\alpha}^2 = \chi_{1,0.95}^2 = 0.004$$

Como $W_{\text{obs}} > \chi_{1,0.95}^2 \rightarrow 136.36266733573592 > 0.004$, rejeitamos H_0

Teste de Razão de Verossimilhança (LRT) Modelo Normal–Normal para RTT Upload

Considere Y_{Ci} e Y_{Si} o *RTT Upload* do Cliente 11 e do Servidor 07, respectivamente, com $i \in [1, n]$, sendo n o número de eventos de cada um deles. Usando o modelo:

$$Y_{Di}|\mu_D \sim N(\mu_D, \sigma^2), \text{ com } \sigma^2 > 0 \text{ conhecida e } \mu_D \text{ a média de RTT Upload do servidor.}$$

Será feito um teste de razão de verossimilhança (LRT) para testar se ambos servidor e cliente possuem a mesma taxa:

$$\bullet H_0 : \mu_{Ci} = \mu_{Si} = \mu \quad \bullet H_1 : \mu_{Ci} \neq \mu_{Si}$$

$$\text{Com a fórmula: } \Lambda = \frac{L_0(\hat{\mu})}{L_1(\hat{\mu}_{Ci}, \hat{\mu}_{Si})}, \quad -2 \log \Lambda \approx \chi_1^2 \text{ sob } H_0.$$

1) Verossimilhança sobre H_0 :

$$\text{Para } \mu_{Ci} = \mu_{Si} = \mu \text{ temos que a verossimilhança é: } L_0(\mu) = \prod_{i=1}^{n_C} f(Y_{Ci}|\mu) \prod_{j=1}^{n_S} f(Y_{Sj}|\mu)$$

Substituindo a fórmula PDF Normal, temos que:

$$\bullet L_0(\mu, \sigma^2 | Y) = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - \mu)^2}$$

$$\bullet \ell_0(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - \mu)^2$$

Derivando e igualando a zero, encontramos a MLE: $\hat{\mu} = \bar{Y}$

$$\text{Logo, } \hat{\mu} = 0.008519338842975208, \quad \text{e} \quad \ell_0 = 15475.455612869657 \quad \rightarrow \quad L_0 \approx \infty$$

2) Verossimilhança sobre H_1 :

$$\text{Para } \mu_{Ci} \neq \mu_{Si} \text{ temos que a verossimilhança é: } L_1(\mu_C, \mu_S) = \prod_{i=1}^{n_C} f(Y_{Ci}|\mu_C) \prod_{j=1}^{n_S} f(Y_{Sj}|\mu_S)$$

Substituindo a fórmula PDF Normal, temos que:

$$\bullet L_1 = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} [\sum_i (Y_{Ci} - \mu_C)^2 + \sum_j (Y_{Sj} - \mu_S)^2]}$$

$$\bullet \ell_1(\hat{\mu}_C, \hat{\mu}_S, \hat{\sigma}^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\hat{\sigma}^2) - \frac{1}{2\hat{\sigma}^2} \left[\sum_i (Y_{Ci} - \bar{Y}_C)^2 + \sum_j (Y_{Sj} - \bar{Y}_S)^2 \right]$$

Derivando e igualando a zero, encontramos as MLEs: $\hat{\mu}_C = \bar{Y}_C$ e $\hat{\mu}_S = \bar{Y}_S$

$$\text{Logo, } \hat{\mu}_C = 0.015223312883435584, \quad \hat{\mu}_S = 0.007644207154297918 \quad \text{e} \quad \ell_1 = 15854.21913660712 \quad \rightarrow \quad L_1 \approx \infty$$

3) Montrando aproximação da LRT:

$$\text{Usando o teste da razão de verossimilhança (LRT):} \quad \Lambda = \frac{L_0(\hat{\mu})}{L_1(\hat{\mu}_C, \hat{\mu}_S)}, \quad -2 \log \Lambda \approx \chi_1^2 \text{ sob } H_0.$$

Para facilitar as contas, os cálculos foram feitos diretamente na forma logarítmica, logo o LRT foi transformado:

$$\Lambda = \frac{L_0(\hat{\mu})}{L_1(\hat{\mu}_C, \hat{\mu}_S)} \quad \rightarrow \quad \log \Lambda = \log \left(\frac{L_0(\hat{\mu})}{L_1(\hat{\mu}_C, \hat{\mu}_S)} \right) = \log(L_0(\hat{\mu})) - \log(L_1(\hat{\mu}_C, \hat{\mu}_S)) = \ell_0(\hat{\mu}) - \ell_1(\hat{\mu}_C, \hat{\mu}_S)$$

Considerando $\bar{Y}$ a média conjunta do RTT, $\bar{Y}_C$ e $\bar{Y}_S$ as médias amostrais e n_C e n_S os tamanhos das amostras do cliente e do servidor, respectivamente, temos que:

$$\bullet \ell_0(\hat{\mu}) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \left[\sum_{i=1}^{n_C} (Y_{Ci} - \hat{\mu})^2 + \sum_{j=1}^{n_S} (Y_{Sj} - \hat{\mu})^2 \right]$$

$$\bullet \ell_1(\hat{\mu}_C, \hat{\mu}_S) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \left[\sum_{i=1}^{n_C} (Y_{Ci} - \bar{Y}_C)^2 + \sum_{j=1}^{n_S} (Y_{Sj} - \bar{Y}_S)^2 \right]$$

Então:

$$\begin{aligned} -2 \log \Lambda &= 2(\ell_1(\hat{\mu}_C, \hat{\mu}_S) - \ell_0(\hat{\mu})) = \\ &= \frac{1}{\sigma^2} [n_C(\bar{Y}_C - \bar{Y})^2 + n_S(\bar{Y}_S - \bar{Y})^2] = \\ &= \frac{1}{\sigma^2} \frac{n_C n_S}{n_C + n_S} (\bar{Y}_C - \bar{Y}_S)^2 \end{aligned}$$

4) Conclusão de hipótese para $\alpha = 0.05$:

Escolhendo um *type 1 error* $\alpha = 0.05$:

$$W_{\text{obs}} = \frac{1}{\hat{\sigma}^2} \frac{n_C n_S}{n_C + n_S} (\bar{Y}_C - \bar{Y}_S)^2 = 757.5270474749262$$

$$\chi_{1,1-\alpha}^2 = \chi_{1,0.95}^2 = 0.004$$

Como $W_{\text{obs}} > \chi_{1,0.95}^2 \rightarrow 757.5270474749262 > 0.004$, rejeitamos H_0

Discussão e Conclusão

Considerando os valores calculados anteriormente (na parte 1 do trabalho) temos que:

Para o Upload Throughput:

- $\beta_C = 166622310.197298$
- $\beta_S = 332902440.99486977$

Para o RTT Upload:

- $\mu_C = 0.01522331288343558$
- $\mu_S = 0.007644207154297918$

Isso nos mostra que os LRT (Likelihood Ratio Test) realizados estão coerentes, pois em ambas as situações rejeitamos H_0 , ou seja, afirmamos que as variáveis β (para Upload Throughput) e μ (para RTT Upload) não são iguais para o cliente 11 e para o servidor 07.

Uso de Ferramentas de IA e Link para o código

Para realizar esse trabalho, foram utilizadas duas IAs: Gemini e ChatGPT gratuito.

As funções principais do Gemini foram tirar dúvidas pontuais sobre a disciplina e auxiliar o uso do latex, além de auxiliar na transferência de informações do arquivo de dados para o documento do relatório.

O ChatGPT foi usado para a compreensão e auxílio na construção dos códigos usados para realizar as contas exigidas pelo trabalho, além de apoio para o aprendizado de como usar as bibliotecas.

Este link direciona ao repositório no github que contém todos os códigos implementados para a realização dos cálculos: https://github.com/igorvalamiel/probability-statistics/tree/main/trabalho_parte2